

PAC 2026 | 优化组初赛【题二：DeepSeek V4 融合算子】

原创 PAC组委会 并行应用挑战赛2026 2026年6月30日 19:13 上海

优化组初赛 • 【题二：DeepSeek V4 融合算子】

01

赛题简介

本赛题聚焦于DeepSeek V4融合算子的性能优化，基于鲲鹏芯片实现indexer_bf16_paged_mqa_logits函数（见indexer_mqa_logits.h）。参赛队需在单NUMA平台上，运用C/C++、汇编及Intrinsics等技术对特定推理规模的算子进行极致调优。在确保输出精度cos_diff小于5e-6的底线上，以最终实现的FLOPS值高低决定成绩。

02

赛题说明

2.1 运行前准备

(1) 按照《算力平台登录操作说明》，先登录到跳板机，然后通过跳板机的软件“MobaXterm”登录到服务节点。

(2) 用户登录到服务节点后，拷贝赛题工程代码indexer_mqa_logits.zip到个人用户目录/fs_real_a800/PACuser000/（这里以用户PACuser000为例，注意不是/home/PACuser000）

```
cp /fs_real_a800/PAC2026/test_case/indexer_mqa_logits.zip /fs_real_a800/PACuser000/
```

(3) 进入目录并解压

```
cd /fs_real_a800/PACuser000/  
unzip indexer_mqa_logitscat.zip
```

2.3 编译

参赛选手对.cpp以及相关的代码进行性能优化之后，可利用本赛题指定GCC和Bisheng两款编译器进行代码编译，推荐Bisheng编译器，以下为两个编译器的环境变量声明和编译命令：

(1) 用GCC编译

```
source /fs_real_a800/PAC2026/HPCKit26/HPCKit/latest/setvars.sh --use-gcc  
g++ -O3 -march=armv9-a+sme+sve2 -fopenmp -lnuma main.cpp -o main
```

(2) 用Bisheng编译

```
source /fs_real_a800/PAC2026/HPCKit26/HPCKit/latest/setvars.sh  
clang++ -O3 -stdlib=libc++ -march=armv9-a+sme+sve2 -fopenmp -rtlib=compiler-rt -  
unwindlib=libunwind -lnuma main.cpp -o main
```

2.4 通过多端提交作业 编写test.sh脚本

```
NUM_THREADS=32  
OMP_NUM_THREADS=$NUM_THREADS OMP_PROC_BIND=close taskset -c 1-$NUM_THREADS  
./main
```

dsub脚本提交作业（示例，非本赛题）

```
source /fs_real_a800/PAC2026/HPCKit26/HPCKit/latest/setvars.sh --use-gcc; #与编译器类型保持一致  
export UCX_TLS=sm,self;  
export OMPI_MCA_btl=vader,self;  
mpirun -np 8 --rankfile rankfile_8x36.txt -x UCX_TLS -x OMPI_MCA_btl -x OMP_NUM_THREADS=36  
-x OMP_PLACES=cores -x OMP_PROC_BIND=close ./tensor_contraction
```

dsub脚本提交作业（本赛题提交任务命令）

```
dsub -x job -o `pwd`/out_%J.log -e `pwd`/err_%J.log -nl PAC -A PAC "bash test.sh"
```

得到以下输出结果：

Submit job <2266> successfully.

注意：该任务大约执行60s以内，请耐心等待结果。

查看out_2266.log 和err_2266.log日志，查看运行结果。

或者命令执行以下命令，查看任务执行情况：

```
djob -l 2266
```

程序的输出如下所示：

```
Total Number of Testcases: 2
=====
Running on Testcase 1:
Parameters: batch_size = 32, next_n = 2, avg_kv = 1024
cos_diff: xxx
Performance: xxx TFLOPS
=====
Running on Testcase 2:
Parameters: batch_size = 128, next_n = 1, avg_kv = 4096
cos_diff: xxx
Performance: xxx TFLOPS
=====
All Tests Ends
```

03 要求和评分规则

3.1 赛题要求

- (1) 精度要求 $\cos_diff < 5e-6$, 根据测试输出的性能结果TFLOPS进行评分。
- (2) 编程语言：C/C++，汇编，intrinsics等
- (3) 编译器：GCC或毕昇编译器（推荐毕昇编译器）
- (4) 不允许使用鲲鹏系列之外的第三方库实现

3.2 评分规则

- (1) 以FLOPS为评分标准，越高越好。成绩计算公式：参赛队成绩 = 30（基础分）+ 70 * （参赛队优化得分-所有参赛队最低得分）/（所有参赛队最高得分 - 所有参赛队最低得分）。
- (2) 取四次测试的Flops均值，Flops值越高，成绩越好。

3.3 作业提交内容

(1) 最终优化后的源代码、编译文件、out_*.log 等文件，存储在/fs_real_a800/PACuser000（替换为个人账户路径）/commit_result/2目录中

(2) 全部代码和编译文件，以及编译环境和命令说明文件一份（Markdown格式：comm.md）

(3) 技术报告PPT（官网资料站下载模板），添加录音，时长5分钟，最终由队长通过报名系统-战队管理提交作品。

修改于2026年7月6日